

ИУ5-64Б Марянян Артур Арамович

Вариант 14

Задача №2.

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему? Для студентов группы ИУ5-64Б - для произвольной колонки данных построить график "Скрипичная диаграмма (violin plot)".

1. Подключение библиотек

Загружаем NuGet-пакеты, совместимые с текущей средой .NET 10.

Используемые пакеты:

- `Microsoft.Data.Analysis` (0.22.1) — работа с табличными данными
- `Microsoft.ML` (3.0.1) — инструменты ML.NET
- `Plotly.NET.Interactive` (5.0.0) и `Plotly.NET.CSharp` (0.12.0) — построение графиков
- `Microsoft.DotNet.Interactive.Formatting` (1.0.0-beta.25070.1) — улучшенное отображение в ноутбуке

```
In [2]: #r "nuget: Microsoft.Data.Analysis, 0.22.1"
#r "nuget: Microsoft.ML, 3.0.1"
#r "nuget: Plotly.NET.Interactive, 5.0.0"
#r "nuget: Plotly.NET.CSharp, 0.12.0"
#r "nuget: Microsoft.DotNet.Interactive.Formatting, 1.0.0-beta.25070.1"
```

Installed Packages

- Microsoft.Data.Analysis, 0.22.1
- Microsoft.DotNet.Interactive.Formatting, 1.0.0-beta.25070.1
- Microsoft.ML, 3.0.1
- Plotly.NET.CSharp, 0.12.0
- Plotly.NET.Interactive, 5.0.0

```
Loading extensions from `C:\Users\artur\.nuget\packages\plotly.net.interactive\5.0.0\lib\netstandard2.1\Plotly.NET.Interactive.dll`
Loading extensions from `C:\Users\artur\.nuget\packages\microsoft.data.analysis\0.22.1\interactive-extensions\dotnet\Microsoft.Data.Analysis.Interactive.dll`
```

2. Импорт пространств имён

Подключаем необходимые пространства имён для удобной работы с данными и визуализацией.

```
In [3]: using Microsoft.Data.Analysis;
using Microsoft.ML;
using Plotly.NET;
using PlotlyNET = Plotly.NET.CSharp.Chart; // алиас для краткости
using System;
using System.Linq;
using System.Globalization;
using System.IO;
```

3. Загрузка набора данных

Файл `Admission_Predict.csv` должен находиться в одной папке с ноутбуком. Загружаем его в `DataFrame`, явно указывая разделитель и культуру (точка как десятичный разделитель).

```
In [10]: var dataPath = Path.Combine(Directory.GetCurrentDirectory(), "Data/Admission_Pre
string[] columnNames = new[] { "Serial No.", "GRE Score", "TOEFL Score", "Univer
Type[] dataTypes = new[] { typeof(int), typeof(float), typeof(float), typeof(flo

var rawData = DataFrame.LoadCsv(dataPath,
    separator: ',',
    header: true,
    columnNames: columnNames,
    dataTypes: dataTypes,
    cultureInfo: CultureInfo.InvariantCulture);

rawData.Head(5).Display();
```

<i>index</i>	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit
0	1	337	118	4	4.5	4.5	9.65	1	0.92
1	2	324	107	4	4	4.5	8.87	1	0.76
2	3	316	104	3	3	3.5	8	1	0.72
3	4	322	110	3	3.5	2.5	8.67	1	0.8
4	5	314	103	2	2	3	8.21	0	0.65

4. Искусственное внесение пропусков

В исходном датасете пропусков нет, поэтому для демонстрации методов обработки мы внесём ~10% пропусков в количественный признак `CGPA` и ~5% — в категориальный `University Rating`.

```
In [11]: var rnd = new Random(42);
for (int i = 0; i < rawData.Rows.Count; i++)
{
```

```

// CGPA - количественный
if (rnd.NextDouble() < 0.1)
    rawData["CGPA"][i] = null;
// University Rating - категориальный (числовой код)
if (rnd.NextDouble() < 0.05)
    rawData["University Rating"][i] = null;
}

Console.WriteLine("Количество пропусков после внесения:");
foreach (var col in rawData.Columns)
{
    // Используем Cast<object?>(), так как object? допускает null
    int nullCount = col.Cast<object?>().Count(v => v == null);
    Console.WriteLine($"{col.Name}: {nullCount}");
}

```

Количество пропусков после внесения:

Serial No.: 0

GRE Score: 0

TOEFL Score: 0

University Rating: 37

SOP: 0

LOR : 0

CGPA: 50

Research: 0

Chance of Admit : 0

5. Обработка пропусков

- **Количественный признак** — **CGPA** : замена средним арифметическим (Mean Imputation).
- **Категориальный признак** — **University Rating** : замена наиболее частым значением – модой (Most Frequent Value).

Вычислим моду и среднее по доступным значениям, затем заполним все **null** в DataFrame.

```

In [12]: // Мода для University Rating (тип float?)
var ratingValues = rawData["University Rating"].Cast<float?>().Where(v => v.HasValue);
var ratingMode = ratingValues.GroupBy(x => x)
    .OrderByDescending(g => g.Count())
    .First().Key;
Console.WriteLine($"Мода University Rating: {ratingMode}");

// Среднее для CGPA
var cgpaValues = rawData["CGPA"].Cast<double?>().Where(v => v.HasValue).Select(v => v);
var cgpaMean = cgpaValues.Average();
Console.WriteLine($"Среднее CGPA: {cgpaMean:F3}");

// Заполнение пропусков
for (int i = 0; i < rawData.Rows.Count; i++)
{
    if (rawData["University Rating"][i] == null)
        rawData["University Rating"][i] = ratingMode;
    if (rawData["CGPA"][i] == null)
        rawData["CGPA"][i] = cgpaMean;
}

```

```
// Проверка
Console.WriteLine("\nПосле обработки:");
foreach (var col in rawData.Columns)
{
    int nullCount = col.Cast<object?>().Count(v => v == null);
    Console.WriteLine($"{col.Name}: {nullCount}");
}
```

Мода University Rating: 3

Среднее CGPA: 8,586

После обработки:

Serial No.: 0

GRE Score: 0

TOEFL Score: 0

University Rating: 0

SOP: 0

LOR : 0

CGPA: 0

Research: 0

Chance of Admit : 0

6. Ответы на вопросы

Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали?

- Для количественного признака `CGPA` применена **замена средним арифметическим** (Mean Imputation).
- Для категориального признака `University Rating` применена **замена модой** (Most Frequent Value), то есть подстановка наиболее часто встречающегося значения.

Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

- Целевая переменная: `Chance of Admit`.
- Признаки, которые войдут в модель: `GRE Score`, `TOEFL Score`, `University Rating`, `SOP`, `LOR`, `CGPA`, `Research`.
- `Serial No.` исключён, так как это просто идентификатор строки, не несущий информации.
- Все оставленные признаки имеют прямую связь с вероятностью поступления: они отражают академическую успеваемость (`CGPA`), результаты стандартизированных тестов (`GRE`, `TOEFL`), престиж текущего университета (`University Rating`), качество мотивационного письма (`SOP`), рекомендаций (`LOR`) и наличие исследовательского опыта (`Research`). Это ключевые факторы, влияющие на решение приёмной комиссии.

7. Скрипичная диаграмма (violin plot) — задание для ИУ5-64Б

Построим скрипичную диаграмму для произвольного столбца. В качестве примера возьмём **CGPA** (средний балл после заполнения пропусков). На диаграмме отображаются плотность распределения, медиана, межквартильный размах, а также линия среднего.

```
In [28]: // Извлечение значений CGPA (после заполнения пропусков)
double[] cgpaArray = rawData["CGPA"]
    .Cast<double?>()
    .Where(d => d.HasValue)
    .Select(d => d.Value)
    .ToArray();

// Построение скрипичной диаграммы
var violinChart = PlotlyNET.Violin<string, double, string>(
    X: Enumerable.Repeat("CGPA", cgpaArray.Length).ToArray(),
    Y: cgpaArray
)
.WithTitle("Скрипичная диаграмма среднего балла (CGPA)")
.WithSize(800, 500);

display(violinChart);
```

Скрипичная диаграмма среднего балла (CGPA)

